Agregacje

Wszystkie agregacje znajdują się w osobnych plikach i są gotowe do uruchomienia, schemat nazewnictwa:

aggregate{nr agregacji w tym pliku}.js

1. Regiony świata, w których najczęściej dochodzi do zamachów (w ostatniej dekadzie).

Usuwamy "nieznane" regiony:

```
var match = {
    $match: {
      region: {
         $ne: "Unknown"
      }
    }
};
```

Grupujemy po id regionu i zapamiętujemy jego nazwę, oraz zliczamy zamachy:

Sortujemy po ilości zamachów:

```
var sort = {
    $sort: {
      count: -1
    }
};
```

Usuwamy z wyniku niepotrzebne nam pole " id":

```
var project = {
    $project: {
        _id: 0
    }
};
```

Składamy zapytanie w całość:

```
var aggregate1a = db.terrorism.aggregate([match, group, sort, project]);
```

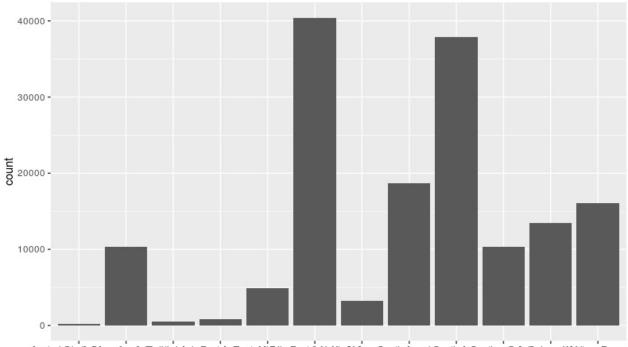
Otrzymaliśmy ranking regionów świata najbardziej dotkniętych zamachami terrorystycznymi od roku 1970. Aby otrzymać dane z ostatniej dekady musimy zrobić małą zmianę (zaznaczam, że dane sięgają początku roku 2016):

```
var match2 = {
    $match: {
        region: {
          $ne: "Unknown"
        },
        iyear: {
          $gte: 2005
        }
    }
};

var aggregate1b = db.terrorism.aggregate([match2, group, sort, project], {
        explain: false
}).pretty();
```

Wynik pierwszego zapytania:

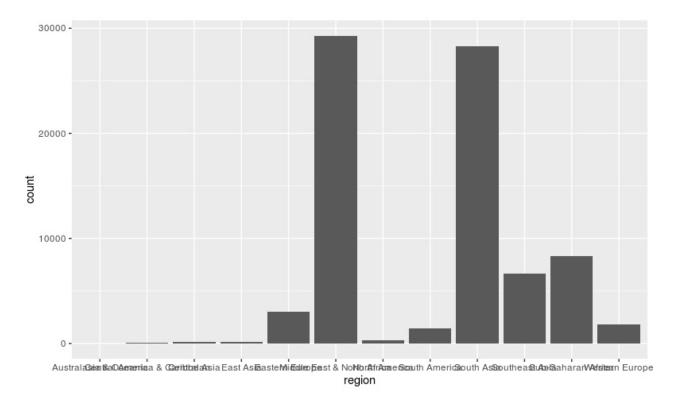
```
{ "region" : "Middle East & North Africa", "count" : 40422 }
    { "region" : "South Asia", "count" : 37841 }
    { "region" : "South America", "count" : 18628 }
    { "region" : "Western Europe", "count" : 16020 }
    { "region" : "Sub-Saharan Africa", "count" : 13434 }
    { "region" : "Southeast Asia", "count" : 10360 }
    { "region" : "Central America & Caribbean", "count" : 10337 }
    { "region" : "Eastern Europe", "count" : 4892 }
    { "region" : "North America", "count" : 3268 }
    { "region" : "East Asia", "count" : 786 }
    { "region" : "Central Asia", "count" : 538 }
    { "region" : "Australasia & Oceania", "count" : 246 }
```



Australa Seian 18an DA emerica & Coerith belancia East As Easte Midballeo East & NoNbratiframe Secuth America outh As Secuthe a Seu Abe Sea hair an West team Europe region

Oraz drugiego:

```
{ "region" : "Middle East & North Africa", "count" : 29297 }
    { "region" : "South Asia", "count" : 28288 }
    { "region" : "Sub-Saharan Africa", "count" : 8348 }
    { "region" : "Southeast Asia", "count" : 6649 }
    { "region" : "Eastern Europe", "count" : 3019 }
    { "region" : "Western Europe", "count" : 1816 }
    { "region" : "South America", "count" : 1471 }
    { "region" : "North America", "count" : 299 }
    { "region" : "Central Asia", "count" : 143 }
    { "region" : "East Asia", "count" : 129 }
    { "region" : "Central America & Caribbean", "count" : 44 }
    { "region" : "Australasia & Oceania", "count" : 30 }
```



Wnioski:

Wciąż najwięcej aktów terroryzmu ma miejsce na Bliskim Wschodzie, w Północnej Afryce i Południowej Azji. Niepokojąco wzrasta również pozycja Europy.

2. Średnia długość przetrzymywania zakładników (w dniach).

Oczywiście chodzi tutaj głownie o porwania.

Najpierw wybieramy te zdarzenia, w których doszło do porwania. Tutaj mamy dwie możliwości: możemy uwzględnić te, których długość trwała 0 dni lub nie. Oczywiście zmieni nam to odrobinę średnią.

Porwania, których długość to 0 dni to porwania krótkie, których czas liczony jest raczej w godzinach. Dla uwzględniania tego faktu postanowiłem ująć takie porwania w średniej:

```
var match = { $match: {
   ishostkid: {
     $eq: 1
   },
   ndays: {
     $gte: 0
   }
}
```

Nasze grupowanie sprowadza się do wyliczenia średniej ze wszystkich pasujących rekordów:

```
var group = {
    $group: {
        _id: null,
```

Dla czytelności możemy pominąć " id":

Składamy agregację w całość:

```
var aggregate2 = db.terrorism.aggregate([match, group, project], {
   explain: false
}).pretty();
```

Wynik:

```
{ "avg" : 35.87450980392157 }
```

Wnioski:

Porwania trwają średnio około miesiąca. Inną sprawą jest to czy porwani po miesiącu giną czy wracają do domów. Magia statystyki.

3. Polska.

Czy w Polsce zdarzały się zamachy terrorystyczne? Jeśli tak, to czy któryś się powiódł? Czy były ofiary? Sprawdźmy to!

161 to ID naszego kraju:

```
var match = {
    $match: {
      country: {
         $eq: 161
      }
    }
};
```

Grupujemy i sumujemy poszczególne wartości:

```
var group = {
    $group: {
        _id: "$country",
        "liczba zamachow": {
        $sum: 1
```

```
},
"udanych": {
    $sum: "$success"
},
"liczba ofiar smiertelnych": {
    $sum: "$nkill"
},
"liczba rannych": {
    $sum: "$nwound"
}
}
}
```

Składamy wszystko w całość:

```
var aggregate3 = db.terrorism.aggregate([match, group], {
    explain: false
}).pretty();
```

Wynik (widać dlaczego w poprzednich zapytaniach pomijaliśmy ID):

```
{
   "_id" : 161,
   "liczba zamachow" : 34,
   "udanych" : 30,
   "liczba ofiar smiertelnych" : 7,
   "liczba rannych" : 30
}
```

Wnioski:

Tutaj pojawia się miejsce na dyskusję p.t.: "Czym właściwie jest zamach terrorystyczny?" Odsyłam do dołączonego <u>PDF</u>.

4. W jakich miastach jest najwięcej zamachów i co jest narzędziem terroru?

Narzędzie terroru nie jest może idealnym określeniem, ale czy, na przykład, samochód można nazwać "bronią"?

Na początek usuwamy "śmieci", czyli zamachy, gdzie miasto jest nieznane:

```
var match = {
    $match: {
       city: {
          $ne: "Unknown"
       }
    }
};
```

Grupujemy po mieście:

```
var group = {
```

```
$group: {
    _id: "$city",
    count: {
          $sum: 1
     }
}
```

Sortujemy malejąco:

```
var sort = {
    $sort: {
      count: -1
    }
};
```

I wybieramy pierwszą, niechlubną, dziesiątkę:

```
var limit = {
    $limit: 10
};
```

Łączymy wszystko w całość:

```
var aggregate4a = db.terrorism.aggregate([match, group, sort, limit], {
   explain: false
}).pretty();
```

Wynik:

```
{ "_id" : "Baghdad", "count" : 6237 }

{ "_id" : "Karachi", "count" : 2530 }

{ "_id" : "Lima", "count" : 2358 }

{ "_id" : "Belfast", "count" : 2102 }

{ "_id" : "Santiago", "count" : 1614 }

{ "_id" : "Mosul", "count" : 1553 }

{ "_id" : "San Salvador", "count" : 1547 }

{ "_id" : "Mogadishu", "count" : 1169 }

{ "_id" : "Istanbul", "count" : 999 }

{ "_id" : "Bogota", "count" : 974 }
```

Wnioski:

Większość miast na tej liście nie powinno być zaskoczeniem. Dziwić może jedynie tak wysoka pozycja Belfastu. IRA przez lata, niestety, nie próżnowała...

Ciekawostka:

W Mongo 3.4 to zapytanie może uprościć. Zamiast osobno grupować i sortować wystarczy użyć \$sortByCount:

```
var sortByCount = {
    $sortByCount: "$city"
};
```

```
var aggregate4b = db.terrorism.aggregate([match, sortByCount, limit], {
  explain: false
}).pretty();
```

Oczywiście wynik takiego zapytania jest dokłanie taki sam. Również szybkość działania się nie zmienia. Dlaczego? Wystarczy zmienić *explain* na *true* i okaże się, że plan wykonania jest taki sam jak w poprzednim przypadku. Tak więc *sortByCount* to jedynie tzw. "cukier syntaktyczny".

A teraz sprawdźmy jakie "narzędzia terroru" najczęściej wykorzystywanow tych miastach:

```
var groupWithWeapons = {
    $group: {
        id: {
            city: "$city",
            weapon: "$weaptype1_txt"
        },
        count: {
            $sum: 1
        }
    };

var aggregate4c = db.terrorism.aggregate([match, groupWithWeapons, sort, limit], {
        explain: false
    }).pretty();
```

Wynik:

```
{
    " id" : {
       "city" : "Baghdad",
       "weapon" : "Explosives/Bombs/Dynamite"
    "count" : 5219
}
   "_id" : {
       "city" : "Lima",
       "weapon" : "Explosives/Bombs/Dynamite"
    },
    "count" : 1690
}
{
    " id" : {
       "city" : "Karachi",
       "weapon" : "Firearms"
    },
    "count" : 1417
}
{
    " id" : {
       "city" : "Santiago",
       "weapon" : "Explosives/Bombs/Dynamite"
    "count" : 1170
```

```
" id" : {
       "city" : "Belfast",
       "weapon" : "Firearms"
   },
    "count" : 1081
{ "id" : { "city" : "Baghdad", "weapon" : "Firearms" }, "count" : 963 }
    " id" : {
       "city" : "Mosul",
        "weapon" : "Explosives/Bombs/Dynamite"
    },
    "count" : 930
}
{
    " id" : {
       "city" : "San Salvador",
       "weapon" : "Explosives/Bombs/Dynamite"
   },
    "count": 735
}
    " id" : {
       "city" : "Belfast",
       "weapon" : "Explosives/Bombs/Dynamite"
   },
    "count" : 673
}
{
    " id" : {
       "city" : "Mogadishu",
       "weapon" : "Explosives/Bombs/Dynamite"
   },
    "count" : 630
}
```

Wnioski:

Zdecydowanie najpopularniejsze wśród terrorystów są materiały wybuchowe.

5. Ile osób zginęło od danego rodzaju broni?

Poprzednia agregacja daje nam pewną podpowiedź. Ale po kolei:

Wybieramy te zamachy, w których ktoś zginął:

```
var match = {
    $match: {
       nkill: {
          $gte: 1
       }
    }
};
```

Grupujemy po typie broni i usuwamy to co po przecinku (to nie tak, że można kogoś trochę zabić, to po prostu statystyka):

Sortujemy malejąco po liczbie ofiar i wybieramy 10 pierwszych wyników:

```
var sort = {
    $sort: {
        zabitych: -1
    }
};

var limit = {
        $limit: 10
    };
```

Składamy zapytanie w całość:

```
var aggregate5 = db.terrorism.aggregate([match, group, sort, limit], {
    explain: false
}).pretty();
```

Wynik:

```
{ "_id" : { "bron" : "Firearms" }, "zabitych" : 156350 }
{ "_id" : { "bron" : "Explosives/Bombs/Dynamite" }, "zabitych" : 141581 }
{ "_id" : { "bron" : "Unknown" }, "zabitych" : 31840 }
{ "_id" : { "bron" : "Melee" }, "zabitych" : 9800 }
{ "_id" : { "bron" : "Incendiary" }, "zabitych" : 5008 }
{
    "_id" : {
        "bron" : "Vehicle (not to include vehicle-borne explosives, i.e., car or truck bombs)"
    },
    "zabitych" : 3101
}
{ "_id" : { "bron" : "Chemical" }, "zabitych" : 430 }
{ "_id" : { "bron" : "Sabotage Equipment" }, "zabitych" : 49 }
{ "_id" : { "bron" : "Other" }, "zabitych" : 46 }
{ "_id" : { "bron" : "Other" }, "zabitych" : 9 }
```

Wnioski:

A jednak nie materiały wybuchowe. O włos wyprzedziła je broń palna. "Melee" to bijatyka.

6. Jakiego typu ataków było najwięcej w danym regionie

świata.

Może da się to zrobić prościej. Ja męczyłem się długo.

Grupujemy po regionie i typie ataku:

```
var group = {
    $group: {
        "_id": {
            "region": "$region_txt",
            "typ": "$attacktype1_txt"
        },
        "countTypes": {
            "$sum": 1
        }
    }
};
```

Sortujemy po raz pierwszy:

```
var sort = {
    $sort: {
      "countTypes": -1
    }
};
```

Grupujemy kolejny raz ale teraz tworząc podobiekty odpowiadające za typy ataku:

Sortujemy kolejny raz:

```
var secondSort = {
    $sort: {
     "liczba": -1
    }
};
```

Chcemy tylko pierwszy obiekt z tablicy typów (już posortowanej) i "liczba":

```
var project = {
    $project: {
        "typy": {
          $slice: ["$typy", 1]
        },
        "liczba": 1
    }
};
```

Składamy agregację w całość:

```
var aggregate6 = db.terrorism.aggregate([group, sort, secondGroup, secondSort, project], {
   explain: false
}).pretty();
```

Wynik:

```
"_id" : "Middle East & North Africa",
    "liczba" : 40422,
    "typy" : [
       {
            "typ" : "Bombing/Explosion",
           "liczba" : 24053
       }
   ]
}
{
    "_id" : "South Asia",
    "liczba" : 37841,
    "typy" : [
       {
           "typ" : "Bombing/Explosion",
           "liczba" : 18247
       }
   ]
}
    " id" : "South America",
    "liczba" : 18628,
    "typy" : [
        {
           "typ" : "Bombing/Explosion",
            "liczba" : 8931
       }
    ]
}
    "_id" : "Western Europe",
    "liczba" : 16020,
    "typy" : [
       {
           "typ" : "Bombing/Explosion",
            "liczba" : 8354
       }
    ]
```

```
{
   " id" : "Sub-Saharan Africa",
   "liczba" : 13434,
   "typy" : [
       {
           "typ" : "Armed Assault",
           "liczba" : 4671
       }
   ]
}
   "_id" : "Southeast Asia",
   "liczba" : 10360,
   "typy" : [
       {
           "typ" : "Bombing/Explosion",
           "liczba" : 4019
       }
   ]
}
   "_id" : "Central America & Caribbean",
   "liczba" : 10337,
    "typy" : [
       {
           "typ" : "Armed Assault",
           "liczba" : 4358
       }
   ]
}
   "_id" : "Eastern Europe",
   "liczba" : 4892,
   "typy" : [
       {
           "typ" : "Bombing/Explosion",
           "liczba" : 2665
       }
   ]
}
   " id" : "North America",
   "liczba" : 3268,
    "typy" : [
       {
           "typ" : "Bombing/Explosion",
           "liczba" : 1518
       }
   ]
}
   " id" : "East Asia",
   "liczba" : 786,
    "typy" : [
       {
           "typ" : "Bombing/Explosion",
           "liczba" : 325
       }
```

```
{
    " id" : "Central Asia",
    "liczba" : 538,
    "typy" : [
       {
           "typ" : "Bombing/Explosion",
           "liczba" : 224
       }
    ]
    "_id" : "Australasia & Oceania",
   "liczba" : 246,
    "typy" : [
       {
            "typ" : "Bombing/Explosion",
           "liczba" : 72
       }
   ]
}
```

Wnioski:

Prawie wszędzie materiały wybuchowe wygrywają.

7. Atak w którym było najwięcej rannych i zabitych.

Wybieramy te ataki, które mają jakichś rannych i zabitych:

Dodajemy liczbę rannych i zabitych:

Wybieramy największą wartość:

```
var sort = {
    $sort: {
```

```
"liczba ofiar": -1
}

;

var limit = {
    $limit: 1
};
```

Składamy wszystko w całość:

```
var aggregate7a = db.terrorism.aggregate([match, project, sort, limit], {
   explain: false
})
```

Wynik:

```
{ "_id" : ObjectId("591ead90043ea5be6ffcd6f3"), "liczba ofiar" : 5513 }
```

Wnioski:

Wynik jest dobry, ale zapytanie złe. W pierwszej fazie użyliśmy logicznego AND zamiast OR. Tego drugiego nie mogliśmy użyć, bo kolumna przyjmuje również wartości nieliczbowe i w kolejnych etapach agregacja by się "wykrzaczyła". Możemy to obejść używając na przykład instrukcji \$switch:

```
var match2 = {
 $match: {
   $or: [{
     nkill: {
       $gte: 0
     }
   }, {
     nwound: {
       $gte: 0
     }
   }]
 }
};
var projectSwitch = {
  $project: {
    "liczba ofiar": {
     $switch: {
       branches: [{
           case: {
              $and: [{
                 $ne: ["$nkill", ""]
               },
                {
                 $ne: ["$nwound", ""]
              ]
            },
              $add: ["$nkill", "$nwound"]
```

```
},
          {
            case: {
              $and: [{
                $ne: ["$nkill", ""]
               },
                 $eq: ["$nwound", ""]
             ]
           },
           then: "$nkill"
         },
            case: {
              $and: [{
                $eq: ["$nkill", ""]
                 $ne: ["$nwound", ""]
              ]
            },
           then: "$nwound"
         }
       ],
       default: 0
   }
 }
};
var aggregate7b = db.terrorism.aggregate([match2, projectSwitch, sort, limit], {
  explain: false
}).pretty();
```

Wynik może i ten sam, ale zapytanie tym razem poprawne.

8. Atak, w którym uczestniczyło najwięcej terrorystów.

Wybieramy te ataki, w których jakiś terrorysta na pewno uczestniczył:

```
var match = {
    $match: {
        nperps: {
          $ne: ""
        }
    }
};
```

Wybieramy ten największy atak:

```
var sort = {
    $sort: {
      nperps: -1
    }
```

```
};
var limit = {
    $limit: 1
};
```

Łączymy agregację w całość:

```
var aggregate8 = db.terrorism.aggregate([match, sort, limit], {
   explain: false
}).pretty();
```

Wynik (dla pełnego obrazu wynikiem jest cały obiekt):

```
" id" : ObjectId("591ead90043ea5be6ffcd0a5"),
"eventid" : NumberLong("199409100003"),
"iyear" : 1994,
"imonth" : 9,
"iday" : 10,
"approxdate" : "",
"extended" : 0,
"resolution" : "",
"country" : 19,
"country_txt" : "Bangladesh",
"region" : 6,
"region_txt" : "South Asia",
"provstate" : "Dhaka",
"city" : "Dhaka",
"latitude" : 23.811388,
"longitude" : 90.412106,
"specificity" : 1,
"vicinity" : 0,
"location" : "",
"summary" : "",
"crit1" : 1,
"crit2" : 1,
"crit3" : 1,
"doubtterr" : 0,
"alternative" : "",
"alternative_txt" : ".",
"multiple" : 0,
"success" : 1,
"suicide" : 0,
"attacktype1" : 9,
"attacktype1_txt" : "Unknown",
"attacktype2" : "",
"attacktype2 txt" : ".",
"attacktype3" : "",
"attacktype3_txt" : ".",
"targtype1" : 3,
"targtype1_txt" : "Police",
"targsubtype1" : 24,
"targsubtype1_txt" : "Police Checkpoint",
"corp1" : "Police",
"target1" : "Police Barracades",
"natlty1" : 19,
```

```
"natlty1 txt" : "Bangladesh",
"targtype2" : "",
"targtype2_txt" : ".",
"targsubtype2" : "",
"targsubtype2 txt" : ".",
"corp2" : "",
"target2" : "",
"natlty2" : "",
"natlty2_txt" : ".",
"targtype3" : "",
"targtype3_txt" : ".",
"targsubtype3" : "",
"targsubtype3_txt" : ".",
"corp3" : "",
"target3" : "",
"natlty3" : "",
"natlty3_txt" : ".",
"gname" : "Islamist Extremists",
"gsubname" : "Fundamentalists",
"gname2" : "",
"gsubname2" : "",
"gname3" : "",
"ingroup" : 421,
"ingroup2" : "",
"ingroup3" : "",
"gsubname3" : "",
"motive" : "",
"guncertain1" : 0,
"guncertain2" : "",
"guncertain3" : "",
"nperps" : 25000,
"nperpcap" : "",
"claimed" : "",
"claimmode" : "",
"claimmode txt" : ".",
"claim2" : "",
"claimmode2" : "",
"claimmode2_txt" : ".",
"claim3" : "",
"claimmode3" : "",
"claimmode3 txt" : ".",
"compclaim" : "",
"weaptype1" : 13,
"weaptype1_txt" : "Unknown",
"weapsubtype1" : "",
"weapsubtype1 txt" : ".",
"weaptype2" : "",
"weaptype2_txt" : ".",
"weapsubtype2" : "",
"weapsubtype2 txt" : ".",
"weaptype3" : "",
"weaptype3 txt" : ".",
"weapsubtype3" : "",
"weapsubtype3_txt" : ".",
"weaptype4" : "",
"weaptype4_txt" : ".",
"weapsubtype4" : "",
"weapsubtype4_txt" : ".",
"weapdetail" : "",
"nkill" : "",
```

```
"nkillus" : "",
    "nkillter" : "",
    "nwound" : 200,
    "nwoundus" : "",
    "nwoundte" : "",
    "property" : 1,
   "propextent" : "",
    "propextent txt" : ".",
    "propvalue" : "",
    "propcomment" : "",
    "ishostkid" : 0,
    "nhostkid" : "",
    "nhostkidus" : "",
    "nhours" : "",
    "ndays" : "",
    "divert" : "",
    "kidhijcountry" : "",
    "ransom" : 0,
    "ransomamt" : "",
   "ransomamtus" : "",
   "ransompaid" : "",
    "ransompaidus" : "",
    "ransomnote" : "",
    "hostkidoutcome" : "",
   "hostkidoutcome_txt" : ".",
   "nreleased" : "",
   "addnotes" : "",
    "scite1" : "",
    "scite2" : "",
    "scite3" : "",
    "dbsource" : "PGIS",
   "INT LOG" : -9,
   "INT IDEO" : -9,
   "INT MISC" : 0,
    "INT ANY" : -9,
    "related" : ""
}
```

Wnioski:

25 tysięcy islamskich terrorystów w 1994 roku walczyło z policją w Bangladeszu.

Java

Dodatkowo zainstalowałem sterownik MongoDB do języka Java i wykonałem w nim przykładowe zapytanie.

Sterownik można zainstalować poprzez narzędzie Maven. Należy w projekcie umieścić plik pom.xml pom.xml o takiej treści i go zsynchronizować:

Niestety budowanie zapytań Mongo w Java jest dość uciążliwe, a składnia niezbyt przyjemna. Dość proste zapytanie wygląda <u>tak</u> tak:

```
import com.google.gson.Gson;
import com.google.gson.GsonBuilder;
import com.mongodb.*;
import java.util.ArrayList;
import java.util.List;
public class Main {
    public static void main( String args[] ) {
        try{
            MongoClient mongoClient = new MongoClient( "localhost" , 27017 );
            DB db = mongoClient.getDB( "nosql" );
            DBCollection coll = db.getCollection("terrorism");
            DBObject myDoc = coll.findOne();
            System.out.println(myDoc);
            DBObject match = new BasicDBObject("$match", new BasicDBObject("region", new BasicDBO
bject("$ne", "Unknown")));
            DBObject groupFields = new BasicDBObject( "_id", "$region");
            groupFields.put("region", new BasicDBObject("$first", "$region txt"));
            groupFields.put("count", new BasicDBObject( "$sum", 1));
            DBObject group = new BasicDBObject("$group", groupFields );
            DBObject sortFields = new BasicDBObject("count", -1);
            DBObject sort = new BasicDBObject("$sort", sortFields );
            DBObject fields = new BasicDBObject(" id", 0);
            DBObject project = new BasicDBObject("$project", fields );
            List<DBObject> pipeline = new ArrayList();
            pipeline.add(match);
```

```
pipeline.add(group);
    pipeline.add((sort));
    pipeline.add(project);

AggregationOutput output = coll.aggregate(pipeline);

Gson gson = new GsonBuilder().setPrettyPrinting().create();
    String json = gson.toJson(output.results());
    System.out.println(json);
}catch(Exception e){
    System.err.print( e.getClass().getName() + ": " + e.getMessage() );
}
}
```